UNIVERSIDADE REGIONAL DE BLUMENAU

CENTRO DE CIÊNCIAS EXATAS E NATURAIS

CURSO DE CIÊNCIA DA COMPUTAÇÃO

Processamento de Linguagem Natural

Trabalho da Unidade 3

Empregando os dados textuais obtidos por cada grupo, avaliem os resultados obtidos da combinação de diferentes representações textuais e técnicas/tarefas de Processamento de Linguagem Natural.

1) Iniciem marcando a lista abaixo com ✔ para as atividades efetivamente realizadas. Se não foram realizadas, incluam uma breve justificativa (ver exemplo abaixo).

	BoW	TF-IDF	Word2Vec	BERT
Clusterização + PCA e visualização	✔	✔	✔	Não deu pra fazer. BERT é um modelo pesado e mais complicado de configurar ia precisar de mais tempo pra entender como funciona
Busca e recomendação	Não testei busca com BoW porque ele só conta quantas vezes a palavra aparece, sem diferenciar rara de comum. Ia dar resultado pior que o TF-IDF	✔	✔	Mesmo motivo da linha de cima, não tive tempo de aprender a usar o BERT direito, então fiquei só com TF-IDF e Word2Vec aqui.
Classificação	✔	✔	✔	Mesmo motivo da linha de cima

Análise de sentimento	(X) Foi realizada ( ) Não foi realizada
Reconhecimento de Entidades Nomeadas	(X) Foi realizada ( ) Não foi realizada
Extração de Relações	( ) Foi realizada (X) Não foi realizada

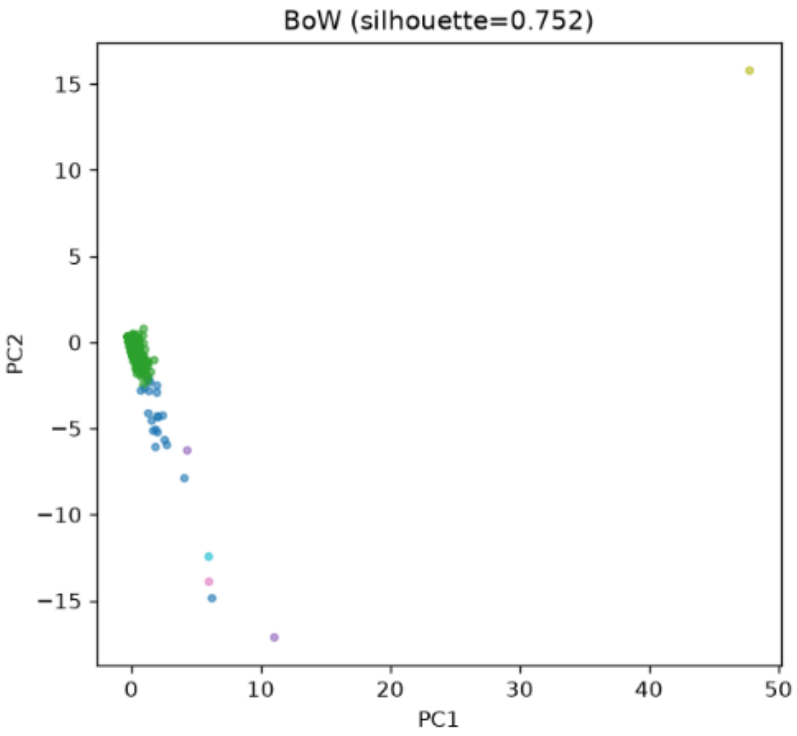
Extração de Relações : A maioria das reviews é frase curta e solta ("bom jogo", 10/10", "fun"). Testei em algumas reviews mesmo assim e não saiu nenhuma relação, entãovi que não ia valer a pena insistir nisso.

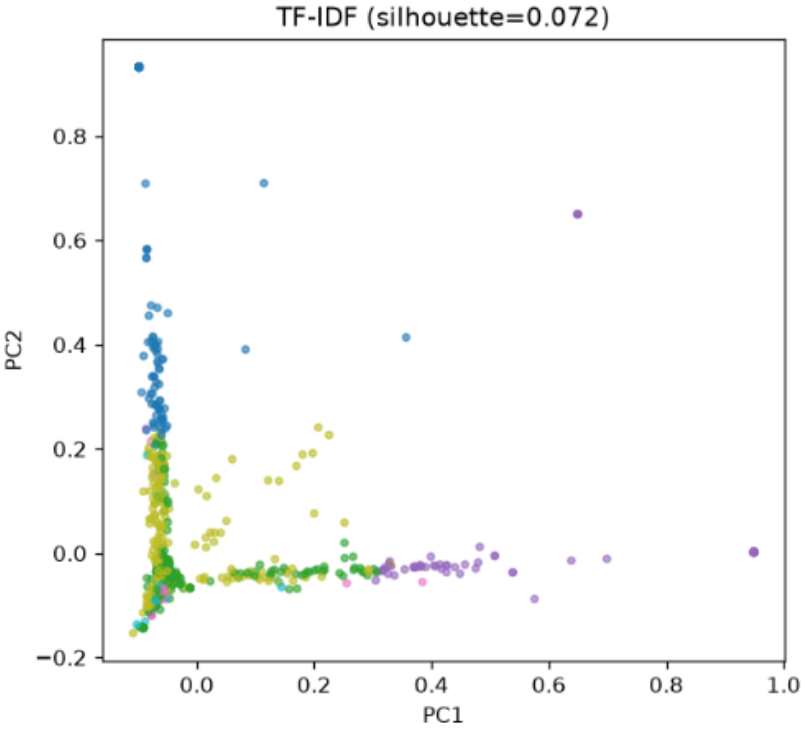
2) Avaliem qualitativamente, a partir dos resultados e da leitura dos textos, qual representação gerou clusters mais representativos para os dados. Qual a quantidade de clusters que melhor expressou as características originais dos dados? Insiram imagens e interpretem as métricas intra e interclusters.

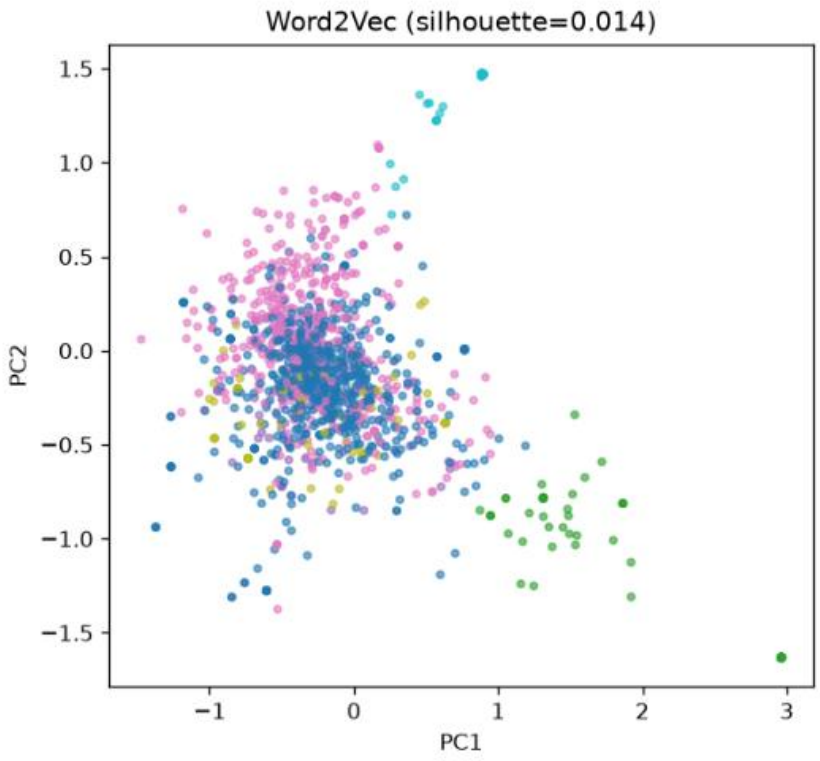
Olhando só o número, o BoW "venceu" disparado (silhouette = 0,752, contra 0,072 do TF-IDF e 0,014 do Word2Vec). Mas é enganoso: olhando o tamanho dos clusters, 98% das reviews do BoW caíram num cluster só, e os outros 5 são 1-2 documentos isolados (reviews muito longas, com contagens brutas muito acima da média, o BoW não normaliza, então esses outliers de magnitude inflam o silhouette sem que o agrupamento faça sentido de verdade).

Representação	Tamanhos dos 6 clusters
BoW	20, 1469, 2, 1, 1, 1
TF-IDF	92, 950, 83, 44, 290, 35
Word2Vec	631, 77, 44, 508, 73, 161

TF-IDF e Word2Vec (normalizados) produziram divisões bem mais equilibradas. Por isso, mesmo com silhouette mais baixo, considero o TF-IDF a representação mais representativa*:* um dos clusters concentra reclamações reais de cheaters no CS2.


BoW (silhouette=0.752)
15
10
5
0
−5
−10
−15
PC2
0
10
20
30
40
50
PC1


TF-IDF (silhouette=0.072)
0.8
0.6
0.4
0.2
0.0
−0.2
PC2
0.0
0.2
0.4
0.6
0.8
1.0
PC1



Testei K=4, 6 e 8, K=6 equilibrou melhor separação e interpretabilidade. O silhouette junta duas coisas num número só: o quanto os documentos de um mesmo cluster são parecidos entre si, e o quanto esse cluster está longe dos outros. O caso do BoW mostra o problema disso: o número ficou alto só porque tinha uns poucos documentos muito fora do padrão (bem mais longos que o resto), e não porque os grupos realmente fazem sentido

3) Apresentem resultados de busca e analisem criticamente a qualidade dos top-3 e top-5 documentos retornados para cada representação. Os resultados são utilizáveis em um contexto real? Como poderiam ser combinados ou melhorados?

Consulta: "too many cheaters and hackers ruining the game".

#	TF-IDF	Word2Vec
1	"too many cheaters" (0,574)	"to many cheaters" (0,934)

| 2 | "to many cheaters" (0,574) | "Too many cheaters in this game" (0,934) |

| 3 | "Too many cheaters in this game" (0,574) | "So many cheaters jfc" (0,934) |

| 4 | "So many cheaters jfc" (0,574) | "too many cheaters" (0,934) |

| 5 | "...bots there are and hackers..." (0,462) | "filled with too many cheaters" (0,933) |

Achado: nas duas representações, os top-4 são praticamente a mesma frase reescrita, variações quase idênticas que sobreviveram à deduplicação exata. Mostra que a base tem redundância quase-duplicada, e que uma busca de verdade precisaria agrupar essas variações antes de exibir resultado. A diferença aparece só no 5º lugar: o TF-IDF trouxe uma review mais diversa; o Word2Vec (treinado do zero, corpus pequeno) ficou preso em mais uma variação de "cheaters". Uso real: nenhuma das duas seria confiável hoje, resultados redundantes e sem captura real de inônimos. Melhoraria com:

(1) deduplicação por similaridade antes de exibir resultados e

(2) um embedding pré-treinado em vez de treinado do zero.

4) Foi possível treinar um classificador? Como ele se comportou a partir de dados novos? Alguma representação textual favorece classificações mais precisas? Quais? Foi utilizada alguma técnica utilizando modelos de linguagem ou de modelos de decisão? Explique.

Alvo voted_up:

Representação	Acurácia	F1 (negativa)	F1 (positiva)
BoW	0,873	0,568	0,925
TF-IDF	0,870	0,562	0,923
Word2Vec	0,779	0,459	0,861

BoW e TF-IDF empatam no topo, à frente do Word2Vec, sentimento em review curta depende de palavras isoladas fortes ("cheater", "love", "laggy"), que BoW/TF-IDF capturam direto, a média de vetores do Word2Vec borra esse sinal. Em 3 frases novas

fora do dataset, o TF-IDF acertou as duas de polaridade clara e errou a neutra ("it's okay, nothing special but playable"), esperado, já que o modelo só aprendeu a distinguir dois extremos.

Técnica: Regressão Logística sobre representações lexicais/vetoriais.

5) Análise de sentimentos, Extração de Entidades Nomeadas e Extração de Relações são aplicáveis aos dados coletados? Em caso positivo, que tipo de resultado foi obtido?

Análise de sentimento: o classificador da pergunta 4 já cumpre esse papel, binário, apoiado no rótulo que a própria Steam fornece. Não fiz uma escala de intensidade à parte, por falta de rótulo para isso.

NER: testado com spaCy em inglês. Encontrou poucas entidades úteis, a maioria das reviews não cita pessoa, organização ou lugar, o que aparece costuma ser falso positivo. Aplicabilidade baixa neste corpus: reviews de jogo giram em torno de mecânica/sentimento, não de entidades do mundo real.

Extração de Relações: não implementei. A técnica precisa de frases completas, reviews são a maior parte fragmentos ("fun", "10/10", "good").

6) As técnicas estudadas auxiliam na concretização do projeto apresentado na Unidade 1? Expliquem.

A minha proposta inicial tinha 5 tarefas, avancei três:

- Classificação**:** já tenho um classificador funcional, baseline razoável em TF-IDF.

- Recuperação de informação: a busca por similaridade é o mecanismo que essa tarefa precisa, ainda numa versão simples/lexical.

- Recomendação: agrupar por similaridade é um primeiro passo, mas os clusters fracos mostram que vou precisar de embeddings pré-treinados antes de confiar nisso.

- Agentes: ainda não implementado.